

PDF CABULOSO: O TERROR DOS EXTRATORES

Caso 1: Ligaduras e Caracteres Especiais

O pássaro voou com eficiência (eff) e futilidade (fu) pela floresta fluida (flu). Muitos extratores quebram palavras como 'eficiência' gerando 'e■ciência' ou sumindo com o 'fi'. Acentuação pesada para testar encoding UTF-8 / Latin-1: Ações, ênfase, órfão, jabuticaba, ímã, vovó, amável, balaústre.

Caso 2: Texto em Múltiplas Colunas (Ordem de Leitura)

Coluna Esquerda: Este texto deve ser lido completamente antes de passar para a coluna da direita. Extratores ruins misturam as linhas horizontalmente, lendo 'Coluna Esquerda: Coluna Direita:' na mesma linha.

Coluna Direita: Se o seu extrator juntar as duas colunas em uma única linha de texto, o fluxo lógico foi quebrado e o algoritmo falhou no teste de segmentação de layout.

Caso 3: Tabela Complexa com Células Mescladas

Região	Dados do Trimestre (Q1 & Q2)		Status
	Mês 1	Mês 2	
Norte	R\$ 12.500	R\$ 14.200	Aprovado
Sul / Sudeste (Mesclado)	R\$ 45.000	R\$ 48.900	Pendente

Caso 4: Espaçamentos Fantasma e Caracteres Invisíveis

Testando espaçamentos longos e blocos. Quebra de linha manual com '\n' dentro do bloco de texto. Texto colado na borda invisível para testar delimitadores de caixas de texto (Bounding Boxes).

Caso 5: Texto Oculto (Branco no Branco) - Caça às Bruxas

Abaixo existe um segredo que humanos não veem, mas leitores de código bruto sim:

Caso 6: Alinhamento de Números Flutuantes (Faturas)

Item	Código	Preço Unitário	Total
Parafuso de Titânio Ultra Fino 3mm	PF-9982	R\$ 1,50	R\$ 15,00
Placa de Circuito Integrado Complexo X	CI-1040	R\$ 1.420,00	R\$ 1.420,00
Mão de Obra Especializada Noturna	MO-001	R\$ 850,33	R\$ 2.551,00