

Aula 10 — Gráficos, Charts e Construção de Visualizações Eficazes com Análise Exploratória

Autor: Elmo Batista de Faria

Problema

Como escolher e construir visualizações de dados adequadas para analisar diferentes tipos de informações, identificar padrões, tendências, distribuições e relacionamentos, evitando gráficos inadequados que possam dificultar a interpretação dos dados?

A aula aborda a escolha do gráfico de acordo com o objetivo da análise — comparação, composição, distribuição ou relacionamento — e utiliza a Análise Exploratória de Dados (EDA) para identificar padrões, valores ausentes, outliers e relações entre variáveis. Na prática, o aluno utiliza o Apache Superset para construir, personalizar e organizar diferentes tipos de gráficos a partir de dados armazenados no PostgreSQL.

Objetivos de Aprendizagem

Ao final da aula, o aluno deverá ser capaz de:

- Compreender a importância da escolha do tipo de gráfico para representar os dados.
- Identificar as principais categorias de visualização: comparação, composição, distribuição e relacionamento.
- Selecionar gráficos de barras, linhas, colunas, pizza, barras empilhadas, histogramas, box plots e dispersão de acordo com o objetivo da análise.
- Compreender as características e aplicações dos diferentes tipos de gráficos.
- Utilizar visualizações para identificar padrões e tendências nos dados.
- Identificar valores atípicos (outliers) utilizando gráficos box plots e gráficos de dispersão.
- Analisar a distribuição dos dados utilizando histogramas e box plots.
- Investigar relacionamentos entre variáveis utilizando gráficos de dispersão.
- Aplicar conceitos de Análise Exploratória de Dados (EDA) para compreender melhor um conjunto de dados antes de análises mais complexas.
- Utilizar o Apache Superset para criar diferentes tipos de visualizações.
- Criar gráficos de barras para comparar valores entre categorias.
- Criar gráficos de linhas para analisar tendências ao longo do tempo.
- Criar gráficos de pizza
- Criar gráficos de dispersão para analisar relações entre variáveis.
- Criar gráficos de barras e analisar a composição dos dados ao longo do tempo.
- Personalizar visualizações, ajustando títulos, rótulos, eixos, legendas e demais elementos disponíveis no Superset.
- Organizar diferentes visualizações em um dashboard, criando uma apresentação coerente dos dados.
- Avaliar a clareza e a capacidade de comunicação de uma visualização, buscando produzir gráficos que sejam compreensíveis e autoexplicativos.

Conteúdo da Aula

Gráficos, Charts e Construção de Visualizações Eficazes com Análise Exploratória

2.1 A Escolha do Gráfico Certo: Uma Decisão Crítica

Discutimos a importância da visualização de dados e os princípios da percepção visual. Hoje, vamos aprofundar na prática, explorando os tipos de gráficos mais comuns e, crucialmente, **quando usar cada um deles**. A escolha do gráfico é a base para uma visualização eficaz, pois o gráfico errado pode distorcer a mensagem ou torná-la incompreensível.



Figura 1 - tipos de Gráficos

2.1.1 Categorias de Gráficos e Seus Usos

Podemos categorizar os gráficos com base no tipo de relacionamento que eles buscam expressar:

- **Comparação:** Como os valores se relacionam entre si?
- **Composição:** Como as partes contribuem para o todo?
- **Distribuição:** Como os dados estão espalhados?
- **Relacionamento:** Existe uma correlação entre duas ou mais variáveis?

2.1.1.1 Gráficos de Comparação

- **Gráfico de Barras (Bar Chart):** Ideal para comparar valores entre diferentes categorias. Pode ser vertical ou horizontal. Use para comparar quantidades discretas.
- **Exemplo:** Vendas por produto, número de usuários por região.
- **Gráfico de Linhas (Line Chart):** Perfeito para mostrar tendências ao longo do tempo ou para comparar múltiplas séries temporais. Conecta pontos de dados para ilustrar continuidade.
- **Exemplo:** Vendas mensais, crescimento de usuários ao longo dos anos.
- **Gráfico de Colunas Agrupadas/Empilhadas:** Para comparar subcategorias dentro de categorias maiores ou para mostrar a composição de um todo ao longo do tempo.
- **Exemplo:** Vendas por produto e por trimestre (agrupado), participação de mercado de produtos ao longo do tempo (empilhado).

2.1.1.2 Gráficos de Composição

- **Gráfico de Pizza (Pie Chart) / Rosca (Donut Chart):** Mostra a proporção de cada categoria em relação ao todo. **Use com cautela:** eficaz apenas para poucas categorias (2-5) e quando as proporções são significativamente diferentes. O cérebro humano tem dificuldade em comparar áreas ou ângulos com precisão.
- **Exemplo:** Distribuição percentual de vendas por categoria de produto (se houver poucas categorias).
- **Gráfico de Barras Empilhadas (Stacked Bar Chart):** Melhor que o gráfico de pizza para mostrar a composição de um todo, especialmente quando há mais categorias ou quando se compara a composição entre diferentes grupos.
- **Exemplo:** Composição de custos por departamento ao longo dos anos.

2.1.1.3 Gráficos de Distribuição

- **Histograma:** Mostra a distribuição de uma única variável numérica, dividindo os dados em "caixas" (bins) e contando quantos pontos de dados caem em cada caixa. Útil para entender a forma, o centro e a dispersão dos dados.
- **Exemplo:** Distribuição de idades de clientes, distribuição de valores de transações.
- **Gráfico de Caixa (Box Plot):** Exibe a distribuição de dados através de seus quartis, mediana e valores atípicos. Bom para comparar a distribuição entre diferentes grupos.
- **Exemplo:** Distribuição de salários por cargo, distribuição de tempo de resposta de servidores por região.

- **Gráfico de Dispersão (Scatter Plot):** Embora também usado para relacionamento, pode mostrar a distribuição de pontos de dados em um plano bidimensional. Útil para identificar aglomerados ou lacunas.
- **Exemplo:** Distribuição de clientes por idade e renda.

2.1.1.4 Gráficos de Relacionamento

- **Gráfico de Dispersão (Scatter Plot):** O gráfico mais comum para mostrar a relação entre duas variáveis numéricas. Permite identificar correlações, tendências e clusters.
- **Exemplo:** Relação entre investimento em marketing e vendas, altura vs. peso.
- **Gráfico de Bolhas (Bubble Chart):** Uma variação do gráfico de dispersão que adiciona uma terceira variável numérica, representada pelo tamanho da bolha.
- **Exemplo:** Vendas vs. Lucro por produto, com o tamanho da bolha representando o número de unidades vendidas.

2.2 Análise Exploratória de Dados (EDA) com Visualizações

A **Análise Exploratória de Dados (EDA)** é uma abordagem para analisar conjuntos de dados para resumir suas principais características, muitas vezes com métodos visuais. A EDA é crucial para entender os dados antes de aplicar modelos complexos ou construir dashboards finais. Ela nos ajuda a:

- Detectar erros e valores ausentes.
- Identificar padrões e tendências.
- Testar hipóteses.
- Descobrir relações entre variáveis.
- Selecionar as variáveis mais importantes.

2.2.1 O Papel da Visualização na EDA

Durante a EDA, as visualizações são nossas melhores amigas. Elas nos permitem rapidamente:

- **Ver a Distribuição:** Histogramas e box plots revelam a forma dos dados.
- **Identificar Outliers:** Pontos fora do padrão em gráficos de dispersão ou box plots.
- **Entender Relações:** Gráficos de dispersão e de linha mostram como as variáveis se movem juntas.
- **Comparar Grupos:** Gráficos de barras e box plots lado a lado.

2.3 Roteiro Prático: Criando Gráficos no Apache Superset

Neste roteiro, vamos usar o Apache Superset para criar diferentes tipos de gráficos a partir dos dados que preparamos no PostgreSQL. Usaremos a interface "Explore" do Superset, que é a ferramenta principal para a criação de visualizações.

2.3.1 Preparação de Dados Adicionais (Opcional, mas Recomendado)

Para ter mais dados para explorar, vamos adicionar mais algumas entradas à nossa tabela `vendas_teste` no PostgreSQL.

1. Conecte-se ao seu PostgreSQL (via **psql** ou DBeaver/pgAdmin):

```
psql -h localhost -U superset_user -d superset_data
```

2. Insira mais dados:

```
INSERT INTO vendas_teste (data_venda, produto, valor) VALUES
("2023-10-04", "Produto B", 180.00),
("2023-10-05", "Produto C", 300.00),
("2023-10-06", "Produto A", 175.00),
("2023-10-07", "Produto B", 220.00),
("2023-10-08", "Produto C", 280.00),
("2023-10-09", "Produto A", 160.00),
("2023-11-01", "Produto A", 190.00),
("2023-11-02", "Produto B", 250.00),
("2023-11-03", "Produto C", 320.00),
("2023-11-04", "Produto A", 185.00),
("2023-11-05", "Produto B", 230.00),
("2023-11-06", "Produto C", 310.00);
```

Saia do **psql** (\q).

2.3.2 Criando Gráficos no Superset

Abra o Superset (<http://localhost:8088>) e faça login.

3. **Acessar o Dataset:**

- Vá em **Datasets** no menu superior.
- Clique no dataset **vendas_teste** (ou o nome que você deu a ele).
- Isso o levará para a interface **Explore**.

4. **Gráfico de Barras: Vendas por Produto**

- **Visualization Type:** Selecione **Bar Chart**.
- **Time Column:** Deixe em branco ou selecione **data_venda** se quiser filtrar por tempo.
- **Metrics:** Clique em **+ ADD METRIC** e selecione **SUM(valor)**. Você pode renomear para **Total Vendas**.
- **Group By:** Selecione **produto**.
- **Run Query:** Clique para gerar o gráfico.
- **Personalização:** Explore as abas **Customize** para mudar cores, rótulos, títulos, etc.
- **Salvar:** Clique em **SAVE** no canto superior direito. Dê um nome como **Vendas por Produto - Barras** e salve em um novo dashboard **Meu Primeiro Dashboard**.

5. **Gráfico de Linhas: Vendas ao Longo do Tempo**

- No menu superior, vá em **Charts** -> **+ Chart**.
- Selecione o dataset **vendas_teste** e **Choose a visualization** como **Line Chart**.
- **Time Column:** Selecione **data_venda**.
- **Time Grain:** Selecione **Month** (Mês) para ver a tendência mensal.
- **Metrics:** **SUM(valor)** (Total Vendas).
- **Run Query.**

- **Salvar:** Salve como **Vendas Mensais - Linhas** e adicione ao **Meu Primeiro Dashboard**.
6. **Gráfico de Pizza: Proporção de Vendas por Produto (Exemplo de Uso Cauteloso)**
- No menu superior, vá em **Charts** -> **+ Chart**.
 - Selecione o dataset **vendas_teste** e **Choose a visualization** como **Pie Chart**.
 - **Metrics:** **SUM(valor)** (Total Vendas).
 - **Group By:** Selecione **produto**.
 - **Run Query**.
 - Observe como é fácil comparar as fatias. Se tivéssemos muitos produtos, seria difícil. Salve como **Proporção Vendas por Produto - Pizza** e adicione ao **Meu Primeiro Dashboard**.
7. **Gráfico de Dispersão: Valor da Venda por Data (com Produto como Cor)**
- No menu superior, vá em **Charts** -> **+ Chart**.
 - Selecione o dataset **vendas_teste** e **Choose a visualization** como **Scatter Plot**.
 - **X-Axis:** **data_venda**.
 - **Y-Axis:** **valor**.
 - **Color:** **produto**.
 - **Run Query**.
 - Salvar como **Vendas por Data e Produto - Dispersão** e adicione ao **Meu Primeiro Dashboard**.

2.3.3 Exercício Prático

8. **Crie um Gráfico de Barras Empilhadas:** Modifique o gráfico de barras **Vendas por Produto - Barras** para mostrar a composição das vendas por produto ao longo dos meses. Você precisará adicionar **data_venda** ao **Group By** e usar **Time Grain** como **Month** ou **Year**.
9. **Explore um Histograma:** Se você tivesse uma coluna numérica com mais variação (e.g., **idade_cliente**), crie um histograma para ver a distribuição. Para a tabela **vendas_teste**, você pode tentar criar um histograma da coluna **valor** para ver a distribuição dos valores das vendas.
10. **Refine seus Gráficos:** Para cada gráfico que você criou, vá na aba **Customize** e experimente diferentes opções de cores, títulos, rótulos de eixos e legendas para torná-los mais claros e esteticamente agradáveis. O objetivo é que eles sejam autoexplicativos. Salve as alterações.
11. **Acesse o Dashboard:** Vá em **Dashboards** no menu superior e clique em **Meu Primeiro Dashboard**. Você verá todos os gráficos que salvou lá. Reorganize-os arrastando e soltando para criar um layout mais lógico. (Não se preocupe com o design final ainda).
12. **Criar o gráfico de recomendações da aula 9:**

Passo 1: Criar o Gráfico de Recomendações

Vá em **Charts** no menu superior e clique em **+ CHART**.

Selecione o Dataset das recomendações que você adicionou no Passo 1.

Escolha o tipo de visualização:

Opção ideal (Aula 10): Selecione **Bar Chart** (Gráfico de Barras).

Clique em **CREATE NEW CHART**.

Configure o gráfico na barra lateral esquerda:

Dimensions / X-Axis: Coloque a coluna do produto recomendado (ex: produto_recomendado ou nome).

Metrics: Adicione a métrica da Similaridade (ex: AVG(similaridade) ou MAX(similaridade)).

Sort By: Ordene pela similaridade em ordem decrescente (para os mais similares aparecerem no topo).

(Opcional) Se tiver a nota de avaliações, você pode adicionar no gráfico ou configurar como cor/legenda.

Clique no botão RUN QUERY (ou Atualizar) para renderizar o gráfico na tela.

No canto superior direito, clique em SAVE:

Chart Name: Top Recomendações de Produtos.

Add to Dashboard: Selecione seu dashboard ou crie um novo (ex: Dashboard de Recomendações).

Clique em SAVE & GO TO DASHBOARD.

Passo 2: Como deixar público no Superset

Para permitir que qualquer pessoa visualize o gráfico ou o dashboard:

1. Pegar o Link Direto (Permalink)

No seu Dashboard no Superset, clique no menu de três pontinhos (...) no canto superior direito.

Clique em Copy permalink to clipboard (Copiar link permanente).

Esse link leva direto para a visualização do seu dashboard.

2. Permitir Acesso Sem Login (Público)

Por padrão, o Superset exige usuário e senha. Para liberar o acesso público:

Vá no menu de engrenagem no canto superior direito > Settings > List Roles.

Procure pela role Public e clique no ícone de editar (lápis).

No campo de permissões, adicione:

can read on Dashboard

datasource access on [nome_do_seu_banco]

Salve. Agora, qualquer pessoa com o link do seu Superset conseguirá abrir e ver o gráfico no navegador sem precisar fazer login!